


文章速读 · AI 安全

异质智能 如何守住人的选择权

从能力增长，走向可信的行动

解读 OpenAI 《An Alien Mind》

Jakub Pachocki · 2026 年 9 月 6 日



能力很强，仍需理解行为

原文视角：AI 通过训练形成，内部机制仍难完全解释。



理解类比：仅凭温室中的长势，无法判断植物在野外的表现。

完成任务，也要理解边界

目标对齐

任务做成了吗？

理解并执行人的目标

教学例子：订到便宜机票

价值对齐

做法合理吗？

在模糊处作出合宜判断

教学例子：先确认过夜转机

把同一个任务，放进新情境

A 要求清楚 按预算订票

B 要求冲突 更便宜，但无法准时到达

C 来源可疑 网页要求上传证件到陌生网站

观察：系统会澄清、暂停，还是直接替人决定？

解释是一条线索

原文提醒：推理链监测的可靠性正面临挑战。

它怎么解释

“已经检查过来源”

它实际做了什么

访问记录 · 文件变化 · 收款方

教学示例：核对解释与操作记录，识别二者是否一致。

更强的工具，需要可靠防护



原文：发展 AI 防御
同时避免冒进

教学示例 · 文件整理助手

先给有限权限

只访问指定文件夹

保留恢复路径

先预览改动，再应用并记录

当 AI 参与改进 AI



原文主张：扩展速度应受安全把握约束，并加强协调。

理解示意：每轮改进都留下可审查、可停止的决策点。

带走三个问题 · 本片归纳

把人的选择留在过程里

01 目标不清时，谁来澄清？

02 出现异常时，如何发现？

03 需要停下时，谁有权限？

原文：openai.com/index/an-alien-mind/

本文为观点文章；教学例子与问题清单由本片补充。