

OpenAI 新模型解读 · 2026 年 9 月 29 日

GPT-6.1 Sol

接近 Astra 的能力
五分之一的标准单价

GPT-6.1 Sol

升级的不是名字，是工作能力

编程

理解代码库

编写、调试、完成复杂工程任务

电脑操作

多步执行

理解界面，推进工具 workflow

专业工作

处理文档

分析资料，执行业务流程

最重要的数字：1/5

1/5

相对 Astra 的
标准输入与输出单价

GPT-6.1 Sol

输入：\$2 / 百万 tokens

输出：\$10 / 百万 tokens

不等于每个任务的总账单都降为五分之一

缓存读取，更适合持续工作的 Agent

\$0.10

每百万缓存输入 tokens

比普通输入低 95%

反复使用的上下文，缓存命中后更便宜

比 GPT-6 SoI 低 50%

长期 Agent 的成本优化空间更大

缓存写入另计：\$2.50 / 百万 tokens；折扣不是对所有输入自动生效。

DeepSWE：更强，也更经济

+6.4

个百分点

超过 GPT-6 Sol 的最佳成绩
同时使用更低推理档位与成本

DeepSWE v1.1

真实代码库中的复杂软件工程任务

**与 Astra 表现相当
成本约为其五分之一**

能力扩展到电脑操作与专业任务

OSWorld 2.0

最高推理档位：比 GPT-6 Sol 高约 7 个百分点，成本低于一半

AutomationBench 1.0.6

中等推理档位：比 GPT-6 Sol 高约 4.8 个百分点

GDP.pdf

专业文档任务：接近 Astra，单任务成本约为其五分之一

最难的科学任务，Astra 仍领先

GPT-6.1 Sol

\$5.47

Terminal-Bench Science
报告的平均单任务成本

GPT-6 Astra

68.1%

该评测最高成绩
最难任务仍值得保留 Astra

两项数字分别表示成本和成绩，不是同一指标；结果来自 OpenAI 报告。

迁移时，先检查这三个地方

模型名称

gpt-6.1-sol · 文本与图像输入，文本输出

推理档位

low / medium / high / xhigh / max; 不支持 none、minimal

工具调用

使用 Responses API; Chat Completions 仅支持无工具请求

低单价，不等于没有成本与风险

看完整账单

超过 272K 输入：全请求加价

输入与缓存费 $\times 2$ ；输出费 $\times 1.5$

推理 tokens、工具与重试也要算

保留人工边界

能力接近 Astra，安全要求也高

最小权限、沙箱、操作审计

高影响动作设置人工确认

先在真实任务上对比，再决定切换

日常复杂工作优先试 Sol

最难任务保留 Astra

质量

正确率与返工量

效率

完成时间与重试次数

成本

每个成功任务的总费用