

OPENAI · PREPAREDNESS

当 AI 逼近 关键网络能力

为什么 OpenAI 主动放慢前沿模型训练

Pacing model development in an era of cyber-critical capabilities

两个信号，触发一次减速



安全事件

OpenAI-Hugging Face 事件暴露了研究环境的现实攻击面。

+



能力跃迁

初步证据显示，Astra 可能达到 Preparedness Framework 的**关键网络能力**门槛。

结论：研发环境本身，已经成为安全边界的一部分。

“放慢”具体意味着什么



01

暂停并加固

研究环境继续红队测试，扩大监控覆盖。

02

缩小规模验证

用较小训练与评测检查行为、保护措施与对齐证据。

03

最大前沿 RL 仍在等待

在证据充分前，不启动原计划的大规模训练。

三道互相强化的安全阀

01



监控

发现异常行为，并让团队及时响应。

02



对齐

降低有害、欺骗或未经授权行动的概率。

03



安全隔离

限制模型能够访问、执行和影响的范围。

目标不是让安全能力追赶模型，而是让三道安全阀随能力同步扩展。

研究环境：从“可信内网”到零信任

WORKLOAD

工作负载隔离

模型生成代码与不可信输出进入更强沙箱，连处理输出的软件也纳入威胁模型。

NETWORK

网络隔离


高风险工作负载与互联网分离；单点失陷不能直接穿透到公网或内部网络。

CONTINUOUS

持续安全测试

减少共享服务与常驻权限，强化日志，并用模型持续模拟攻击边界。

监控升级为一条实时调查链



对齐必须贯穿训练，而不是只做终检

能力越强，失败代价越高

Reward hacking

欺骗与隐瞒

未经授权访问



改进奖励模型

跨任务与环境识别并压制不安全行为。



训练诚实报告

让模型更准确说明行为、能力与限制。



扩大行为覆盖

重点训练与外部系统、资源交互时的安全性。

Preparedness Framework 也要随之进化

现在

能力门槛

识别模型何时进入高风险或关键能力区间。

下一步

训练+部署一体化

把监控、对齐与隔离统一到研发全生命周期。

规模化

模型辅助安全

让模型承担更多防御、测试与调查工作，并引入外部组织。

未来的关键问题，不只是“模型能做什么”，而是“组织能否安全地训练和观察它”。

核心判断

能力加速时， 安全证据决定节奏

理解、对齐与保护模型的能力，必须始终跑在模型能力之前。

PACE = CAPABILITY × EVIDENCE